

Cours de NLP — Rapport final

Lucas FANDINO PEREZ

Date : Juin 2026

Cours : Traitement automatique du langage naturel (NLP) - Panggih Kusuma Ningrum

Exercice 1 : Pré-traitement de texte

- **Lien GitHub:**
https://github.com/Dev-IA-P5-2027/lucas.fandinoperez/blob/ed580f491afb6155606f8016a7ba12ea5638e6be/NLP/rapport_final/NLP_codingexercice_lucasFP.ipynb
- **Fichiers :** NLP_codingexercice_lucasFP.ipynb · jeu de données SMS_test.csv (125 SMS étiquetés Spam/Ham)

Ce que j'ai appris

- Mise en œuvre d'un pipeline complet de pré-traitement de texte sur un véritable jeu de données SMS (SMS_test.csv).
- Maîtrise des étapes clés de normalisation : mise en minuscules, suppression du bruit et de la ponctuation, et tokenisation.
- Compréhension des différences pratiques et de la mise en œuvre des techniques de réduction du texte par **racinisation (stemming)** et **lemmatisation**.
- Filtrage des tokens non pertinents par la suppression des mots vides (stop words) afin de transformer les messages bruts en jeux de données propres et prêts à l'analyse.

Difficultés rencontrées

- Traiter des données SMS bruitées et non structurées (argot, abréviations, émojis et fautes de frappe) sans perdre le sens sémantique essentiel.
- Trouver l'équilibre entre la réduction agressive de la racinisation et la lemmatisation, plus coûteuse en calcul mais grammaticalement plus précise.

Pistes d'amélioration

- Développer des listes de mots vides avancées et spécifiques au domaine, adaptées au jargon des SMS.
 - Intégrer des règles regex personnalisées pour normaliser le bruit textuel moderne (par exemple, les voyelles répétées comme « loooooove »).
-

Exercice 2 : NER personnalisé avec spaCy

- **Lien GitHub :**
https://github.com/Dev-IA-P5-2027/lucas.fandinoperez/blob/cbdc3a02d21539d9d0b8d65003b77936a369c2fb/NLP/rapport_final/Spacy_Custom_NER.ipynb

- **Fichiers** : Spacy_Custom_NER.ipynb · jeu de données : [Kaggle Medical NER](#)

Ce que j'ai appris

- Comment annoter des données textuelles et entraîner un modèle personnalisé de reconnaissance d'entités nommées (NER) avec spaCy sur un jeu de données du domaine médical.
- Création d'entités spécialisées pour isoler avec succès des tokens propres au domaine, tels que les **affections médicales** (MEDICALCONDITION), les **médicaments** (MEDICINE) et les **agents pathogènes** (PATHOGEN).
- Mise en forme du texte annoté brut dans les structures d'entraînement natives **DocBin** de spaCy et construction de la configuration d'entraînement de zéro.

Difficultés rencontrées

- Éviter l'oubli catastrophique du modèle (s'assurer qu'il apprend les nouvelles entités personnalisées sans oublier les entités standard comme les dates ou les noms).
- Gérer les entités qui se chevauchent ou les annotations incohérentes dans le jeu de données d'entraînement médical.

Pistes d'amélioration

- Augmenter la taille du jeu de données d'entraînement avec des structures de phrases plus variées pour améliorer la détection des limites d'entités.
- Régler les hyperparamètres des composants du pipeline spaCy afin de maximiser la précision et le rappel.

Exercice 3 : Projet d'analyse de sentiments sur des avis TripAdvisor

- **Lien GitHub** :
https://github.com/Dev-IA-P5-2027/lucas.fandinoperez/blob/cbdc3a02d21539d9d0b8d65003b77936a369c2fb/NLP/rapport_final/Hotel_Reviews_Sentiment_Analysis_Model_Comparison.ipynb
- **Lien diapo de présentation** :
https://github.com/Dev-IA-P5-2027/lucas.fandinoperez/blob/f7fa03e10c92d8185ac95a8fcef5c5035878196e/NLP/rapport_final/Sentiment_Analysis_Challenge.pptx.pdf

Ce que j'ai appris

- Analyse comparative des approches d'analyse de sentiments fondées sur des règles par rapport à celles fondées sur les plongements (embeddings).
- Mise en œuvre de **TextBlob** (polarité/subjectivité fondées sur un lexique), **VADER** (optimisé spécifiquement pour les réseaux sociaux et les textes courts) et **FLAIR** (framework de plongements contextuels à l'état de l'art).
- Compréhension de la manière dont la structure du texte influence les scores de sentiment selon les différentes bibliothèques.

Difficultés rencontrées

- Gérer le sarcasme, les négations et les expressions émotionnelles ambiguës qui trompent les modèles fondés sur des règles (TextBlob/VADER).
- Dataset largement déséquilibré avec 91 % d'avis favorable, focus sur le F1-score nécessaire

- Manque de spécialisation dans le domaine et notamment termes propres à l'hôtellerie

Pistes d'amélioration

- Ajuster le seuil pour se focaliser sur la classe négative (avis négatifs minoritaires) (quick win option)
 - Construire un modèle d'ensemble par vote combinant la rapidité de VADER et la compréhension contextuelle approfondie de FLAIR.
 - Affiner (fine-tuning) un modèle de type transformer sur des données spécifiques au domaine plutôt que de s'appuyer entièrement sur des poids prêts à l'emploi.
-

Exercice 4 : Démonstration de traduction automatique avec des LLM et Gradio

- Lien GitHub :
https://github.com/aDev-IA-P5-2027/lucas.fandinoperez/tree/cbdc3a02d21539d9d0b8d65003b77936a369c2fb/NLP/rapport_final/machine-translation-project

Ce que j'ai appris

- Intégration de grands modèles de langage (LLM) génératifs pour effectuer des tâches de traduction multilingue précises.
- Construction et déploiement d'une interface web claire et réactive à l'aide de **Gradio** pour les interactions utilisateur.
- Utilisation de métriques d'évaluation NLP académiques standardisées : les scores **BLEU** (chevauchement de n-grammes axé sur la précision) et **ROUGE** (plus longue sous-séquence commune, axée sur le rappel).

Difficultés rencontrées

- Relier les sorties génératives aux métriques de scoring structurelles, car les LLM reformulent souvent les phrases de manière exacte mais sont pénalisés par les métriques de correspondance exacte de n-grammes.
- Optimiser la vitesse d'inférence du modèle au sein de l'interface Gradio pour éviter les délais d'attente côté utilisateur.

Pistes d'amélioration

- Mettre en œuvre des techniques de prompting few-shot pour guider le LLM vers des styles de traduction spécifiques (formel ou familier).
- Ajouter des métriques d'évaluation alternatives modernes comme **COMET** ou **BERTScore** pour évaluer la similarité sémantique plutôt que le simple chevauchement de tokens en surface.